

数学 I，数学 A

第2問 後半（データの分析）（配点 15）

講座用オリジナル問題

〔2〕 次の表は、UCI Machine Learning Repository の Iris データセットに含まれるアヤメ（Iris setosa）のうち、10個体について、がく片の長さ x と花弁の長さ y を測定したものである。元の単位は cm であるが、ここでは 10 倍して mm で表している。

個体	がく片の長さ x (mm)	花弁の長さ y (mm)
A	54	17
B	45	13
C	46	10
D	51	19
E	50	16
F	49	15
G	51	15
H	54	15
I	48	16
J	52	14

出典：UCI Machine Learning Repository, Iris dataset の一部をもとに作成。問題文・設問はオリジナル。





図1 散布図と、花弁の長さ y の箱ひげ図

(1) 花弁の長さ y のデータを小さい順に並べると

10, 13, 14, 15, 15, 15, 16, 16, 17, 19

である。したがって、第1四分位数は **ア**，中央値は **イ**，第3四分位数は **ウ** であり、四分位範囲は **エ** である。

外れ値を「第1四分位数から四分位範囲の1.5倍を引いた値より小さい値，または第3四分位数に四分位範囲の1.5倍を加えた値より大きい値」と定める。このとき，外れ値となる個体は次の0～4のうち **オ** である。

0 A	1 B	2 C	3 D	4 外れ値はない
-----	-----	-----	-----	----------

(2) 以下，平均，分散，共分散はすべて「データの個数で割る」ものとする。がく片の長さ x と花卉の長さ y の平均をそれぞれ $\bar{x}$ ， $\bar{y}$ とすると

$$\bar{x} = \text{カキ}, \quad \bar{y} = \text{クケ}$$

である。また，計算すると

$$\Sigma(x_i - \bar{x})^2 = 84, \quad \Sigma(y_i - \bar{y})^2 = 52$$

であり，

$$\Sigma(x_i - \bar{x})(y_i - \bar{y}) = \text{コサ}$$

である。よって， x と y の共分散は

$$\frac{\text{シス}}{\text{セ}}$$

であり，相関係数に最も近い値は，次の0～4のうち **ソ** である。

0 0.20	1 0.40	2 0.57	3 0.75	4 0.95
--------	--------	--------	--------	--------

数学 I，数学 A

第2問 後半（データの分析）（続き）

(3) 花卉の長さ y をすべて2倍した新しいデータを

$$z_i = 2y_i \quad (i=1,2,\dots,10)$$

とする。このとき、 z の平均は **タチ**，分散は

ツテト
ナ

である。また、 x と z の共分散は、 x と y の共分散の **ニ** 倍であるから

ヌネ
ノ

である。さらに、 x と z の相関係数は、 x と y の相関係数と比べて **ハ**。

0 等しい	1 2倍になる	2 4倍になる	3 半分になる
-------	---------	---------	---------

(4) 図1を見た生徒は、次のように話している。

太郎：花卉の長さ y では、個体 C は外れ値と判断できそうだね。

花子：でも、外れ値を除けば必ず相関が強くなるとは限らないよ。実際にこのデータではどうなるかな。

個体 C を除いた9個体のデータについて相関係数を計算すると、約 **ヒ** である。

0 0.20	1 0.39	2 0.58	3 0.76	4 0.91
--------	--------	--------	--------	--------

したがって、個体 C を除くと、このデータにおける x と y の相関係数は **フ**。

0 大きくなる	1 小さくなる	2 変わらない	3 必ず 0 になる
---------	---------	---------	------------

(5) 次の 0～4 の記述のうち、正しいものは **ヘ**，**ホ** である。ただし、解答の順序は問わない。

0 個体 C は、 x の値についても最小である。
1 個体 C を除くと、このデータの相関係数はもとの値より大きくなる。
2 y をすべて2倍すると、 y の四分位範囲も2倍になる。
3 y をすべて2倍すると、 x と y の共分散も2倍になる。
4 y の値にすべて5を加えると、 x と y の共分散は5だけ大きくなる。